



Guía
compacta de

Data Engineering

Índice

**Introducción a la ingeniería de
datos en Databricks**

3

Guía y mejores prácticas

16

Migración de cargas de trabajo ETL de Apache Spark™ a Databricks 17

Estudios de casos

22

**NFCU: Usar datos en tiempo real para abrir camino
a la personalización de la experiencia de los miembros** 23

**Cincinnati Reds: Triunfar dentro y fuera del campo
con analítica de béisbol de vanguardia** 27

01

Introducción a la ingeniería de datos en Databricks

Introducción a la ingeniería de datos en Databricks

A medida que el volumen de datos sigue expandiéndose y la complejidad de las fuentes y la distribución de datos se intensifica, las organizaciones luchan por mantener el control de sus datos y beneficiarse eficazmente de ellos. Según una reciente **Encuesta de Valoración de Datos de IDC**, el 41 % de las organizaciones respondieron que los datos están cambiando más rápido de lo que pueden seguir. Combinado con una mayor presión para capitalizar la IA, las organizaciones de todos los sectores se enfrentan a nuevos desafíos impulsados por los datos que deben superar para seguir siendo competitivas en su campo. Muchas de ellas que corren la carrera de los datos se encuentran con la misma dura verdad:

Todo, desde la IA hasta la analítica, la inteligencia empresarial (BI) y las aplicaciones, comienza con buenos datos.

Esta realidad subraya la importancia de construir canalizaciones de datos confiables que puedan ingerir o transmitir grandes volúmenes de datos de manera eficiente y asegurar una alta calidad de los datos de manera confiable y a gran escala. Una plataforma unificada y una buena ingeniería de datos son componentes esenciales para el éxito en cualquier iniciativa de análisis, inteligencia empresarial (BI) e inteligencia artificial (IA). Con la solución adecuada de ingeniería de datos, las organizaciones pueden transformar sus datos propietarios en activos empresariales reales y, a la inversa, utilizar esos conocimientos empresariales para desarrollar sus aplicaciones y sus flujos de trabajo autónomos.

Este libro usa orientación práctica, patrones útiles, mejores prácticas y ejemplos reales para ayudarle a entender cómo los ingenieros de datos pueden afrontar los desafíos de esta nueva era y cómo la plataforma de inteligencia de datos de Databricks puede ayudarlo en su recorrido.

¿Qué es la ingeniería de datos?

La ingeniería de datos es la práctica de extraer datos sin procesar de una fuente de datos y procesarlos para que se almacenen y organicen para un caso de uso posterior, como el análisis de datos, la BI o el entrenamiento de modelos de aprendizaje automático (ML). En otras palabras, es el proceso de preparar los datos para que se pueda extraer su valor.

Una forma útil de pensar en la ingeniería de datos es mediante el uso del siguiente marco, que incluye tres partes principales:

1. Ingesta

La ingesta de datos es el proceso de incorporar datos de una o más fuentes a una plataforma de datos. Estas fuentes pueden ser archivos almacenados en las instalaciones o en servicios de almacenamiento en la nube, bases de datos, aplicaciones y, cada vez más, flujos de datos que generan eventos en tiempo real.

2. Transformación

La transformación de datos toma los datos ingeridos sin procesar y usa una serie de pasos (denominados “transformaciones”) para filtrarlos, estandarizarlos, limpiarlos y, por último, agregarlos de manera que se almacenen de forma utilizable. Un patrón popular es la **arquitectura Medallion**, que define tres etapas en el proceso: Bronce, Plata y Oro.

3. Orquestación

La orquestación de datos se refiere a cómo se programa y supervisa un pipeline de datos que realiza la ingesta y transformación, así como al control de las distintas etapas del pipeline y cómo maneja las fallas (por ejemplo, al volver a ejecutar el proceso).

Los desafíos de la ingeniería de datos en la era de la IA

Como se mencionó anteriormente, la ingeniería de datos es fundamental para garantizar datos confiables para las iniciativas de IA, analítica y BI. Los ingenieros de datos que diseñan y mantienen los pipelines ETL y la infraestructura de datos que respalda las cargas de trabajo de analítica y IA se enfrentan a desafíos específicos en este panorama en rápida evolución.

- **Las fuentes de datos dispares representan un desafío para la mayoría de las organizaciones:** ISG predice que para 2026, 8 de cada 10 empresas tendrán sus datos distribuidos entre varios proveedores de nube y centros de datos locales ubicados en diferentes lugares. Esta descentralización genera dependencia de equipos especializados y aislados, pipelines ineficientes, procesos de desarrollo costosos y un tiempo de valorización más lento. Como consecuencia, se restringe el uso de los datos y se frena la innovación.
- **Herramientas fragmentadas:** la mayoría de las empresas confían en múltiples herramientas y servicios externos o en soluciones internas personalizadas para gestionar sus procesos ETL. Estas herramientas suelen estar desconectadas y tener diferentes arquitecturas, interfaces y salidas, lo que suma otro nivel de complejidad a la experiencia de ingeniería de datos y provoca cuellos de botella en los equipos.
- **Manipulación de datos en tiempo real:** desde aplicaciones móviles hasta datos de sensores en las plantas de producción, cada vez se crean y transmiten más datos en tiempo real, lo que requiere un procesamiento de baja latencia para que puedan usarse en la toma de decisiones en tiempo real.
- **Escalamiento de los pipelines de datos de forma confiable:** con la llegada de datos en grandes cantidades y, a menudo, en tiempo real, escalar la infraestructura de cómputo que ejecuta los pipelines de datos es un desafío, en especial, cuando se intenta mantener los costos bajos y el rendimiento alto. Ejecutar los pipelines de datos de manera confiable, monitorearlos y solucionar problemas cuando ocurren fallas son algunas de las responsabilidades más importantes de los ingenieros de datos.

- **Calidad de los datos:** “Garbage in, garbage out”. Contar con datos de alta calidad es esencial para entrenar modelos de calidad y obtener información realmente útil. Garantizar esa calidad de los datos es uno de los principales desafíos para los ingenieros de datos.
- **Gobernanza y seguridad:** la gobernanza de datos se está convirtiendo en un desafío clave para las organizaciones que encuentran sus datos distribuidos en múltiples sistemas, donde un número cada vez mayor de equipos internos busca acceder a ellos y usarlos para diferentes fines. Proteger y gobernar los datos también es una preocupación regulatoria importante que enfrentan muchas organizaciones, en especial, en industrias muy reguladas.

Estos desafíos destacan la importancia de elegir la plataforma de datos correcta para navegar por las necesidades de datos en constante evolución, en especial, en la era de la IA. Sin embargo, una plataforma de datos en esta era también puede ir más allá de abordar únicamente los desafíos de desarrollar soluciones de IA. La plataforma adecuada puede mejorar la experiencia y la productividad de los profesionales de datos, incluidos los ingenieros de datos, al incorporar inteligencia y usar IA para asistir en las tareas diarias de ingeniería.

En otras palabras, la nueva plataforma de datos es una plataforma de *inteligencia* de datos.



La plataforma de inteligencia de datos de Databricks

La misión de Databricks es democratizar los datos y la IA, lo que permite a las organizaciones utilizar sus datos únicos para desarrollar o perfeccionar sus propios modelos de aprendizaje automático y de IA generativa para generar nuevos conocimientos que impulsen la innovación empresarial.

La **Databricks Data Intelligence Platform** está diseñada sobre una **arquitectura lakehouse** para proporcionar una base abierta y unificada para todos los datos y la gobernanza, y está impulsada por un motor de inteligencia de datos que comprende lo que hace únicos a sus datos. Con estas capacidades en su base, la plataforma de inteligencia de datos permite a los clientes de Databricks ejecutar una gran variedad de cargas de trabajo, desde inteligencia de negocios y almacenamiento de datos hasta IA y ciencia de datos.

Para obtener una mejor comprensión de la plataforma Databricks, se presenta en la próxima página una descripción general de las diferentes partes de la arquitectura en relación con la ingeniería de datos. La plataforma de inteligencia de datos de Databricks le permite ejecutar todas sus iniciativas de datos, análisis, BI e IA. Como plataforma 100 % sin servidor, le ofrece funciones integradas como recuperación ante desastres, controles de costos y seguridad empresarial. Los componentes clave presentan Mosaic AI con IA integral tanto para IA generativa como clásica; Databricks SQL, un almacén de datos inteligente sin servidor; ingeniería de datos unificada con Lakeflow, una base de datos integrada con Lakebase; y AI/BI que se integra profundamente con Databricks SQL para extender con facilidad la inteligencia empresarial en toda su empresa.



 databricks
Data Intelligence Platform



 **Mosaic AI**
Inteligencia artificial

 **DB SQL**
Almacenamiento de datos

 **Lakebase**
Base de datos transaccional

 **AI/BI**
Inteligencia empresarial

 **Lakeflow**
Ingesta, ETL, streaming

 **Apps**
Proteger datos y aplicaciones de IA

 **Marketplace**
Mercado de datos e inteligencia artificial

 **Lakehouse**

 **Unity Catalog**

 **DELTA LAKE**

ICEBERG

 **Parquet**

Varios elementos de la Data Intelligence Platform son especialmente relevantes para los ingenieros de datos y vale la pena analizarlos más de cerca. La siguiente sección profundizará en **Lakeflow**, la solución unificada de ingeniería de datos para ingesta, transformación y orquestación. Pero antes, vale la pena comprender los componentes fundamentales de la plataforma que aportan un valor importante para los ingenieros de datos:

GOBERNANZA UNIFICADA Y ABIERTA CON DATABRICKS UNITY CATALOG

Unity Catalog (UC) ofrece un catálogo de datos único y centralizado para gestionar los permisos, la auditoría y el linaje de todos los datos y activos de IA en el lakehouse. Es compatible con los principales formatos abiertos, incluidos Delta Lake, Apache Iceberg™, Hudi y Parquet, por lo que los ingenieros de datos pueden elegir el formato adecuado para sus cargas de trabajo sin la necesidad de depender de un solo proveedor. Con controles de acceso integrados, supervisión de la calidad de los datos y linaje a nivel de columna, Unity Catalog facilita el cumplimiento normativo y la confianza, a la vez que acelera el desarrollo. La interoperabilidad entre formatos y el intercambio seguro de datos a través de **Delta Sharing** garantizan que los ingenieros puedan colaborar entre equipos, plataformas y nubes, y al mismo tiempo que mantienen una gobernanza coherente. Unity Catalog reduce la complejidad, se adapta a las necesidades de las plataformas de datos modernas y mantiene la apertura y confiabilidad como base de cada flujo de trabajo de ingeniería de datos.

ACELERAR LA PRODUCTIVIDAD CON DATABRICKS ASSISTANT

Databricks combina la IA generativa con los beneficios de unificación de un lakehouse para impulsar un motor de inteligencia de datos que comprende la semántica única de sus datos. Esto permite que la plataforma Databricks optimice automáticamente el rendimiento y gestione la infraestructura de manera única para su negocio. A partir de este motor se diseñó **Databricks Assistant**, un asistente de IA con comprensión del contexto que permite interactuar mediante una API conversacional para consultar datos, generar y explicar código, e incluso solucionar problemas. Databricks Assistant ayuda a los profesionales, incluidos los ingenieros de datos, a ser más productivos, ya que reduce el tiempo que se tarda en crear nuevos pipelines de datos y en solucionar problemas de los pipelines.


BASE DE DATOS INTEGRADA Y LISTA PARA LA IA CON LAKEBASE

Toda aplicación se ejecuta sobre una base de datos, y Postgres es la opción preferida para la mayoría de los desarrolladores de aplicaciones. **Databricks Lakebase** es una base de datos Postgres totalmente gestionada, sumamente integrada en la arquitectura lakehouse, que facilita la creación de aplicaciones de datos e IA. Lakebase sincroniza de forma automática los datos del lakehouse y las características o modelos en una base de datos operativa para aplicaciones de baja latencia, paneles de control y sistemas CRM. Con Lakebase, los equipos de ingeniería pueden centrarse en proporcionar información a las aplicaciones en lugar de crear canalizaciones personalizadas, gestionar la infraestructura o administrar bases de datos.

UN ECOSISTEMA RICO EN SOLUCIONES DE DATOS


La Data Intelligence Platform se basa en tecnologías de código abierto y utiliza estándares abiertos, por lo que las soluciones de datos líderes se pueden aprovechar con lo que se construya en el lakehouse.

Un gran conjunto de **socios tecnológicos** facilita y simplifica la integración de las tecnologías en las que usted confía al migrar a Databricks, por lo que no se quedará atrapado en un stack tecnológico de datos cerrado.



Ingeniería de datos unificada con Databricks Lakeflow

Lakeflow simplifica y unifica la experiencia de ingeniería de datos con una plataforma ETL moderna e integrada construida sobre la plataforma de inteligencia de datos. Su interfaz intuitiva y centralizada para la ingesta, transformación y orquestación de datos reduce la proliferación de herramientas, acelera el tiempo de producción y obtención de valor, y hace que la ingeniería de datos esté al alcance de más usuarios en toda la organización. Lakeflow permite a los equipos de ingeniería de datos avanzar más rápido y de forma más confiable, sin comprometer la gobernanza, la escalabilidad ni el rendimiento.




Lakeflow está compuesto por tres componentes profundamente integrados:

- **Lakeflow Connect** para la ingesta
- **Lakeflow Spark Declarative Pipelines** para la transformación
- **Lakeflow Jobs** para la orquestación

Además, **Lakeflow Designer** ofrece una experiencia sin código diseñada para que cualquier profesional pueda crear pipelines de datos sobre Lakeflow.

INGESTA DE DATOS CON LAKEFLOW CONNECT


Databricks permite a las organizaciones ingestar datos de manera eficiente desde distintos sistemas hacia una arquitectura lakehouse única, abierta y unificada. **Lakeflow Connect** ofrece conectores sencillos para la ingesta de datos desde aplicaciones, bases de datos, almacenamiento en la nube, buses de mensajería y más, directamente a su lakehouse. Estos conectores integrados permiten una ingesta incremental eficiente de extremo a extremo, configuración fácil mediante una interfaz de apuntar y hacer clic o API, y gobernanza unificada a través de Unity Catalog. Con Lakeflow Connect, Databricks sigue innovando, ampliando la variedad de fuentes de datos soportadas con conectores integrados y gestionados, así como conectores con más opciones de personalización. Zerobus Ingest permite enviar datos de eventos directamente al lakehouse sin necesidad de un bus de mensajería, lo que simplifica la ingesta para casos de uso como IoT, flujo de clics, telemetría y otros similares. Auto Loader es un conector totalmente personalizable que proporciona una fuente de Structured Streaming para procesar los datos de manera incremental y eficiente a medida que llegan al almacenamiento en la nube, y su uso se recomienda con Declarative Pipelines.



Conectores de datos integrados para aplicaciones empresariales, fuentes de archivos y bases de datos

TRANSFORMACIÓN DE DATOS PARA SPARK DECLARATIVE PIPELINES


Spark Declarative Pipelines es un marco ETL declarativo (diseñado sobre el código abierto Apache Spark™ Declarative Pipelines) que ayuda a los equipos de datos a simplificar y hacer más rentable el ETL tanto de transmisión como por lotes. Tan solo defina las transformaciones que desea realizar en sus datos y deje que Spark Declarative Pipelines se encargue automáticamente de la orquestación de tareas, la gestión de recursos de cómputo, el monitoreo, la calidad de los datos y la gestión de errores. Los ingenieros pueden tratar sus datos como código y aplicar las mejores prácticas modernas de ingeniería de software, como pruebas, manejo de errores, monitoreo y documentación, para desplegar pipelines confiables a escala. Declarative Pipelines es totalmente compatible tanto con Python como con SQL y está diseñado para trabajar tanto con cargas de trabajo de transmisión como por lotes.



Pipelines de datos confiables y simplificados con Spark Declarative Pipelines

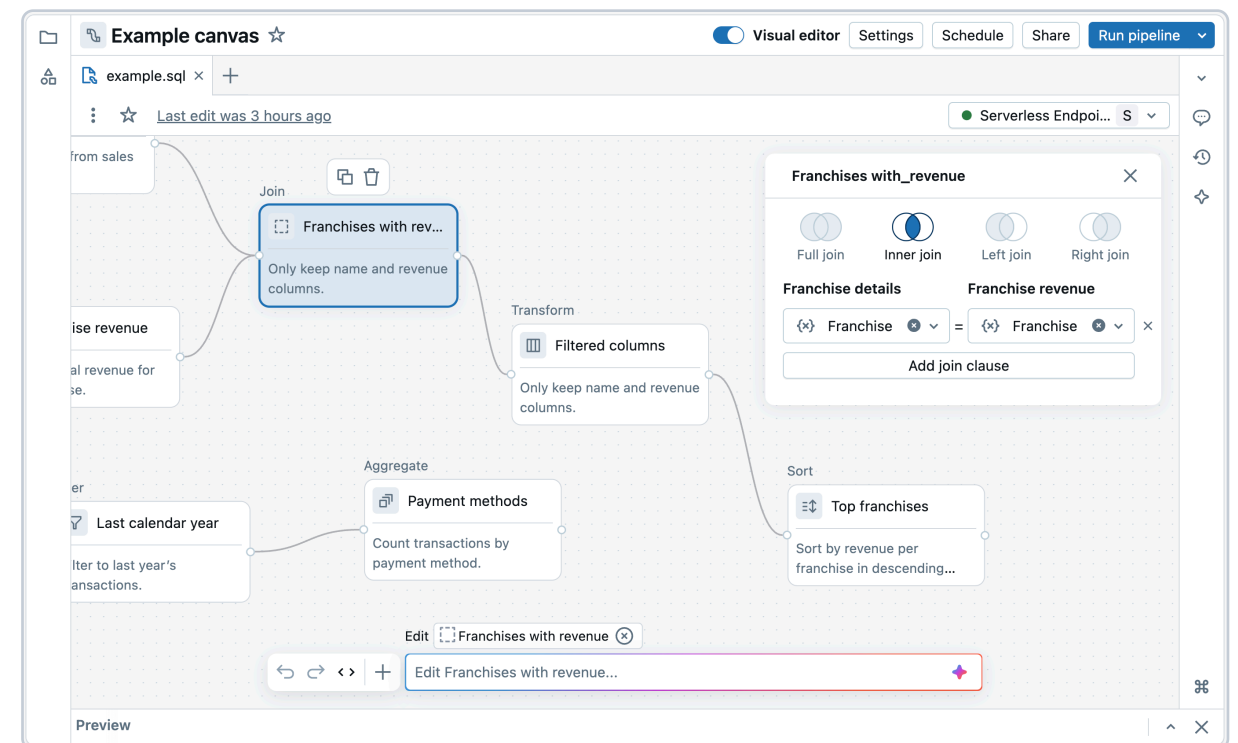
ORQUESTACIÓN UNIFICADA DE DATOS CON LAKEFLOW JOBS

Lakeflow Jobs ofrece una solución de orquestación sencilla y confiable para datos, analítica e IA en la plataforma de inteligencia de datos. Lakeflow Jobs permite definir flujos de trabajo de múltiples pasos para implementar pipelines ETL, flujos de entrenamiento de ML y más. Brinda capacidades avanzadas de control de flujo y soporta distintos tipos de tareas y opciones para activar los flujos de trabajo. Como orquestador nativo de la plataforma, Lakeflow Jobs también proporciona observabilidad avanzada para monitorear y visualizar la ejecución de los flujos, junto con capacidades de alerta y resolución de problemas cuando surgen incidencias. Lakeflow Jobs incluye opciones de cómputo sin servidor, lo que permite aprovechar el escalado inteligente y la ejecución eficiente de tareas.



PIPELINES DE DATOS DE NIVEL DE PRODUCCIÓN, SIN NECESIDAD DE CÓDIGO CON LAKEFLOW DESIGNER

Los proyectos de analítica requieren colaboración entre ingenieros de datos y analistas de negocio, quienes normalmente trabajan en plataformas separadas. Aunque las herramientas sin código pueden ayudar a cerrar esta brecha, todavía hay desafíos relacionados con flujos de trabajo aislados, problemas de producción y productividad limitada de la IA. **Lakeflow Designer** resuelve esto con una herramienta sin código asistida por IA, nativa de la plataforma inteligente de datos de Databricks, que permite a los analistas de negocio y a otras partes interesadas construir pipelines de datos listos para la producción con lenguaje natural. Gracias al impulso de la inteligencia de datos, Lakeflow Designer facilita flujos de trabajo colaborativos y compartidos, y ofrece un recorrido integrado hacia la producción gracias a una IA que comprende su negocio.



Por qué los ingenieros de datos eligen Databricks Lakeflow y la plataforma de inteligencia de datos

Entonces, ¿cómo ayudan la plataforma de inteligencia de datos y Lakeflow con cada uno de los desafíos de ingeniería de datos discutidos anteriormente?

- **Experiencia unificada de ingeniería de datos:** Lakeflow reúne todos los aspectos clave de la ingeniería de datos, desde la ingesta (Lakeflow Connect) hasta la transformación (Spark Declarative Pipelines) y la orquestación (Lakeflow Jobs), en una única solución construida sobre la plataforma de inteligencia de datos. Gracias a una plataforma de datos centralizada y simplificada, puede eliminar los silos entre equipos, reducir la proliferación de herramientas y mejorar la eficiencia operativa.
- **Ingesta eficiente, amplia gama de conectores de datos:** Lakeflow le permite ingerir datos de manera eficiente, ya que incorpora solo nuevos datos o actualizaciones de tablas. Con un conjunto creciente de conectores nativos para fuentes de datos populares, así como una amplia red de socios de ingesta de datos, puede mover fácilmente los datos de sistemas aislados a su plataforma de datos. Ingerir y almacenar sus datos en Delta Lake mientras aprovecha la confiabilidad y escalabilidad de la plataforma de inteligencia de datos es el primer paso para extraer valor de sus datos y acelerar la innovación.
- **Procesamiento de flujos de datos en tiempo real:** Lakeflow simplifica el desarrollo y las operaciones al automatizar los aspectos de producción asociados con la construcción y el mantenimiento de cargas de trabajo de datos en tiempo real. Spark Declarative Pipelines ofrece una forma declarativa de definir pipelines ETL de transmisión, y la transmisión estructurada de Spark ayuda a construir aplicaciones en tiempo real para la toma de decisiones en tiempo real.
- **Pipelines de datos confiables a escala:** Lakeflow usa un escalado automático inteligente y una gestión de recursos optimizada automáticamente para manejar cargas de trabajo a gran escala. Con la arquitectura lakehouse, la alta escalabilidad de los lagos de datos se combina con la alta confiabilidad de los almacenes de datos, gracias a Delta Lake, el formato de almacenamiento que constituye la base del lakehouse.
- **Calidad de los datos:** la alta confiabilidad, que comienza en el nivel de almacenamiento con **Lakehouse Storage** y se une a las características específicas de calidad de datos que ofrece Spark Declarative Pipelines, garantiza una alta calidad de datos. Estas características incluyen establecer “expectativas” de datos para manejar datos corruptos o faltantes, así como reintentos automáticos. Además, tanto Lakeflow Jobs como Spark Declarative Pipelines ofrecen total observabilidad a los ingenieros de datos, lo que hace que la resolución de problemas sea más rápida y sencilla.
- **Gobernanza unificada con intercambio seguro de datos:** **Unity Catalog** ofrece un modelo de gobernanza único para toda la plataforma, lo que garantiza que cada conjunto de datos y pipeline esté gobernado de manera consistente. Los conjuntos de datos se pueden detectar y compartir de manera segura con equipos internos o externos mediante Delta Sharing. Además, debido a que Unity Catalog es una solución de gobernanza multiplataforma, proporciona información valiosa sobre el linaje, lo que permite comprender fácilmente cómo se utiliza cada conjunto de datos y tabla en procesos posteriores y de dónde proviene originalmente.

Conclusión

A medida que las organizaciones buscan innovar al aprovechar sus datos, la ingeniería de datos se convierte en un pilar clave para el éxito, al proporcionar pipelines de datos confiables y en tiempo real que hacen posible la IA. Con Databricks Lakeflow, construido sobre la arquitectura lakehouse y potenciado por inteligencia de datos, los ingenieros de datos están mejor preparados para enfrentar los desafíos críticos del panorama moderno de datos. Al aprovechar las capacidades avanzadas de Lakeflow y de toda la plataforma de inteligencia de datos, los ingenieros de datos no necesitan dedicar tanto tiempo a gestionar pipelines complejos ni a lidiar con problemas de confiabilidad, escalabilidad y calidad de datos. En cambio, pueden centrarse en la innovación y en aportar más valor a la organización.

En la siguiente sección, describimos las mejores prácticas para la ingeniería de datos y casos de uso de integrales basados en ejemplos del mundo real. Desde la ingesta de datos y el procesamiento en tiempo real hasta la orquestación y federación de datos, aprenderá a aplicar patrones probados y a aprovechar al máximo las diferentes capacidades de Lakeflow y la plataforma de inteligencia de datos.

Sumérjase en más prácticas esenciales de ingeniería de datos e historias de clientes en el libro electrónico **Big Book of Data Engineering** (solo en inglés).



02

Guía y mejores prácticas


Migración de cargas de trabajo ETL de Apache Spark™ a Databricks

Por **Dinesh Kumar**

Introducción

Migrar las cargas de trabajo ETL de Spark a Databricks permite un rendimiento más rápido, reduce costos y mejora la escalabilidad. Con soporte integrado para **Delta Lake**, gestión automatizada de recursos de cómputo y un motor de **Spark** optimizado, Databricks simplifica y moderniza sus pipelines de datos.

En este capítulo, abarcaré las prácticas recomendadas clave para una migración fluida y eficiente, que van desde la evaluación de cargas de trabajo hasta la optimización del rendimiento. Ya sea que esté migrando, reestructurando o rediseñando sus pipelines, estos pasos le ayudarán a aprovechar al máximo el potencial de Databricks.



Evaluación y planificación para la migración de Databricks

Una migración exitosa a Databricks comienza con un enfoque estructurado, que incluye un inventario exhaustivo de las cargas de trabajo existentes, la evaluación de la compatibilidad y el establecimiento de objetivos claros para la migración.

1. Haga un **inventario de las cargas de trabajo existentes**: clasifique sus cargas de trabajo como por lotes o en streaming y documente los activos clave para la migración, incluidos los trabajos, los flujos de trabajo, los parámetros, la utilización de recursos, la frecuencia de ejecución y los consumidores de datos. Un inventario completo le proporcionará una visión general clara de los componentes listos para la migración.
2. **Determine la compatibilidad**: identifique cualquier característica propietaria o específica del entorno que pueda no traducirse directamente a Databricks. También debe identificar y evaluar los proveedores de nube y las dependencias de servicios externos para garantizar una integración fluida durante la migración.
3. **Establezca los objetivos de migración**: defina metas claras y criterios de éxito para la migración, como el costo de propiedad, la gobernanza, las mejoras de rendimiento, la escalabilidad y la simplicidad de la arquitectura.
4. **Elija la estrategia de migración correcta**: la clave para una migración exitosa a Databricks es elegir la estrategia adecuada: rehostedaje, refactorización o rediseño. Cada opción tiene sus ventajas y desventajas en cuanto a esfuerzo, flexibilidad y escalabilidad a largo plazo. El rehostedaje es la estrategia más rápida, ya que implica cambios mínimos en las cargas de trabajo. Permite aprovechar de inmediato los beneficios de rendimiento y el costo de Databricks, ya que ofrece un retorno de inversión rápido. Aunque no garantiza una arquitectura completamente optimizada, acelera la obtención de valor y prepara el camino para mejoras futuras.

Para más detalles, consulte nuestra documentación [aquí](#).

Seguridad y control de acceso

A medida que sus datos se amplían en Databricks, es fundamental contar con una seguridad y una gobernanza sólidas. Las herramientas unificadas de Databricks ayudan a centralizar los permisos de datos, lo que permite una innovación descentralizada y segura en todos los equipos.

Unity Catalog es la base para **unificar la gobernanza**, ya que proporciona permisos detallados a través de catálogos, esquemas, tablas, vistas y columnas. También captura el linaje de datos en tiempo de ejecución, facilita el descubrimiento de datos a través del explorador de catálogos y permite el monitoreo mediante registros de auditoría. Unity Catalog también ayuda a proteger los datos sensibles con enmascaramiento de datos integrado y seguridad a nivel de fila.

La federación de identidades simplifica la gestión centralizada de usuarios y grupos al integrarse con proveedores de identidad como Azure AD u Okta. El aprovisionamiento mediante SCIM automatiza la sincronización de usuarios y grupos, lo que permite una gestión de acceso fluida y un inicio de sesión único (SSO) para una mejor experiencia de usuario.

La adopción de la arquitectura **Data Mesh** para la gobernanza federada y la asignación de la propiedad de los datos a equipos específicos de dominio acelera la toma de decisiones, empodera a los equipos para gestionar sus datos y mejora la agilidad y la escalabilidad.

Las plantillas de Terraform también ayudarán a automatizar el despliegue de recursos y a mantener la escalabilidad en toda la plataforma, lo que garantiza la consistencia y seguridad de la infraestructura.

Refactorización y optimización del código

Optimizar y refactorizar su código es fundamental para mejorar la compatibilidad y el rendimiento en Databricks mientras se establece una base sólida para obtener éxito a largo plazo.

ADAPTE EL CÓDIGO PARA QUE SEA COMPATIBLE CON DATABRICKS

Aunque la estrategia de rehospedaje puede acelerar el despliegue, el código heredado podría afectar el rendimiento y la estabilidad. Me gustaría que aprovechara esta oportunidad para auditar y optimizar sus pipelines, y que identifique componentes que quizás no se integren perfectamente con Databricks. Los desafíos comunes incluyen archivos JAR personalizados, UDF de Hive y configuraciones específicas de la infraestructura que podrían requerir una refactorización para alinearse con el entorno nativo de la nube de Databricks. Abordar proactivamente estas cuestiones ayuda a reducir la deuda técnica y garantiza migraciones más fluidas y estables.

REFACTORIZAR LA LÓGICA DE PROCESAMIENTO DE DATOS

La refactorización de la lógica de procesamiento de datos heredada moderniza sus pipelines y simplifica la migración. **Las herramientas Remorph Transpile** y BladeBridge pueden automatizar la conversión de código SQL, lo que reduce el esfuerzo manual. Aprovechar **Delta Lake** mejora la confiabilidad y el rendimiento con características como transacciones ACID y la aplicación de esquemas, lo que garantiza la compatibilidad y ofrece una base escalable para el crecimiento futuro.

Migrar datos de transmisión a Databricks: simplificar y optimizar los pipelines

La migración de los flujos de datos en streaming a Databricks puede desbloquear información más rápida, mejorar el rendimiento y reducir los costos operativos. Ya sea que esté dejando atrás procesadores de flujo heredados o consolidando múltiples herramientas, Databricks ofrece un recorrido de migración fluido, con funciones clave diseñadas para un rendimiento optimizado, escalabilidad y facilidad de gestión.

SPARK DECLARATIVE PIPELINES (SDP): SIMPLIFICACIÓN DE LOS PIPELINES DE DATOS DE TRANSMISIÓN

SDP simplifica la construcción y gestión de pipelines de transmisión al permitirle usar SQL o Python en un formato declarativo. Se encarga automáticamente de la orquestación, los reintentos y las dependencias para que pueda centrarse en la lógica del pipeline en lugar de en los desafíos operativos.

SDP admite datos por lotes y de transmisión, lo que agiliza la migración de las cargas de trabajo de transmisión y mejora la conservación de los pipelines al reducir la necesidad de usar múltiples herramientas o soluciones personalizadas.

CARACTERÍSTICAS PRINCIPALES DE SPARK DECLARATIVE PIPELINES

- **Pipelines de transmisión declarativos:** simplifica la creación de pipelines al eliminar detalles de bajo nivel como la programación, los reintentos y la gestión de estados, ya que permite a los desarrolladores centrarse en la lógica empresarial.
- **Modos por lotes y continuos:** admite tanto el procesamiento de datos por lotes como el de transmisión en tiempo real, lo que ofrece flexibilidad para diversas necesidades de procesamiento de datos.

- **Verificaciones de calidad de datos:** verificaciones integradas de calidad de datos para garantizar un procesamiento preciso de los datos.
- **Evolución del esquema:** adaptarse a los cambios en el modelo de datos reduce el esfuerzo manual y garantiza la robustez del pipeline.
- **Publicación en múltiples catálogos:** permite publicar datos en varios catálogos para lograr flexibilidad en el acceso y la gestión.

AUTO LOADER: INGESTIÓN ESCALABLE CON UNA SOBRECARGA MÍNIMA

Auto Loader facilita la ingesta incremental de archivos desde el almacenamiento en la nube, como por ejemplo, S3, ADLS. Detecta automáticamente los esquemas, se adapta a cambios en tiempo real y maneja cargas de trabajo de alto volumen y baja latencia. Auto Loader es ideal para migraciones de transmisión, ya que garantiza una gestión eficiente y fluida de los pipelines de datos.

STREAMING ESTRUCTURADO (STRUCTURED STREAMING): ANÁLISIS EN TIEMPO REAL A GRAN ESCALA

Structured Streaming, construido sobre Apache Spark, proporciona flexibilidad y resiliencia para su arquitectura de transmisión. Combinado con **Delta Lake**, ofrece procesamiento de baja latencia, semántica de exactamente una vez y cumplimiento de ACID, lo que permite canalizaciones de datos en tiempo real escalables y confiables.

LAKEFLOW CONNECT: INTEGRACIÓN OPTIMIZADA CON FUENTES EXTERNAS

Lakeflow Connect ofrece conectores totalmente gestionados para ingestar datos fácilmente desde aplicaciones SaaS y bases de datos hacia su lakehouse. Impulsado por Unity Catalog y el cómputo sin servidor, garantiza una ingesta incremental rápida, escalable y rentable, ya que mantiene sus datos actualizados y listos para su uso posterior.

Optimizar el almacenamiento y acceso a los datos en Databricks

A medida que los volúmenes de datos crecen, optimizar su almacenamiento y acceso se vuelve crucial para mantener el rendimiento, reducir costos y garantizar la confiabilidad. Databricks ofrece varias características avanzadas para optimizar Delta Lake y mejorar el rendimiento a gran escala.

OPTIMIZACIONES CLAVE:

- **Optimización y compactación de archivos:** resuelva problemas de archivos pequeños con compactación automática y escrituras optimizadas, aunque aún se puede usar la **OPTIMIZACIÓN** para ajustes manuales más precisos. Además, **Liquid Clustering** y **Z-Ordering** permiten reorganizar los datos según campos predictivos para mejorar aún más el rendimiento.
- **Caché de disco y Photon Execution Engine:** Delta Caching guarda los datos más consultados en la memoria o en el SSD para reducir la latencia de las consultas, mientras que Photon Execution Engine ejecuta las cargas de trabajo y consultas de manera más eficiente.
- **Optimización predictiva:** elimina la necesidad de gestionar manualmente las operaciones de mantenimiento de las tablas gestionadas de forma manual en Unity Catalog en Databricks.

Si necesita más información, consulte las [mejores prácticas para la eficiencia de rendimiento](#), la documentación sobre [ajuste del tamaño de archivos](#) y [las operaciones de limpieza de archivos no utilizados \(delta vacuum\)](#).

Gestión y optimización de clústeres en Databricks

Optimizar la configuración de los clústeres es fundamental para equilibrar el rendimiento y costo en Databricks. Es clave adoptar un enfoque consciente de la carga de trabajo y experimentar con distintos tipos de clústeres y configuraciones que se ajusten mejor a los requisitos de su pipeline.

MEJORES PRÁCTICAS:

- **Clústeres de trabajo:** use **clústeres de trabajo** para cargas de trabajo efímeras y así minimizar los costos por inactividad.
- **Tipos de clústeres:** seleccione máquinas virtuales optimizadas para memoria en tareas que requieren mucho caché y máquinas virtuales optimizadas para cómputo en transformaciones de alto rendimiento.
- **Autoescalado:** active el autoescalado para ajustar automáticamente los recursos según la demanda de la carga de trabajo.
- **Soluciones sin servidor:** use soluciones sin servidor para eliminar la sobrecarga de gestión de clústeres para consultas ad hoc y paneles de BI.

Si necesita más información, consulte la [configuración de clústeres](#), [la optimización de costos para el data lakehouse](#), [la Guía completa para optimizar cargas de trabajo en Databricks, Spark y Delta Lake](#) y [cómo conectarse a soluciones de cómputo sin servidor](#).

Pruebas y validación para la migración de cargas de trabajo de ETL

Migrar cargas de trabajo ETL no se trata solo de trasladar código, sino de mantener la calidad de los datos, el rendimiento y la precisión funcional. Automatice pruebas para validar la precisión de los datos y las dependencias del pipeline, así como para medir métricas clave y monitorear mejoras en el rendimiento.

El enfoque recomendado es automatizar las pruebas con herramientas como **Remorph Reconcile**, DataCompy o SQLglot. Estas herramientas ayudan a reducir el esfuerzo manual, lo que aumenta la confianza en el éxito de su migración.

También es fundamental adoptar una estrategia de implementación por fases, al ejecutar los sistemas nuevos y los heredados de manera paralela para validar y monitorear antes de hacer la transición completa a Databricks. Este enfoque garantiza una migración de bajo riesgo con una interrupción mínima.

Gestión y orquestación del flujo de trabajo en Databricks

Migrar la orquestación a **Lakeflow Jobs** puede simplificar la gestión de ETL, mejorar el manejo de dependencias y permitir un monitoreo centralizado. Databricks ofrece soporte nativo para **Apache Airflow** mediante **DatabricksRunNowOperator**, lo que permite migrar la orquestación sin que esto afecte sus DAG existentes. Con el tiempo, se recomienda trasladar los flujos de trabajo a la interfaz visual nativa de Databricks y a la configuración basada en YAML para mayor flexibilidad y facilidad de uso.

Monitoreo y optimización después de la migración

Tras la migración, es crucial mantener un entorno eficiente de Databricks. Las herramientas integradas como **Spark UI**, **Databricks Metrics UI**, **System Tables** y **Cluster Event Logs** pueden ayudarle a obtener información sobre la ejecución, el uso de recursos y el comportamiento del clúster.

A medida que las cargas de trabajo se estabilicen, ajuste el rendimiento analizando los datos en tiempo real. Ajuste los recursos al dimensionar correctamente los clústeres, perfeccionar el escalado automático y optimizar las estrategias de partición o caché para mejorar el rendimiento de las consultas y reducir la E/S.

Hay referencias adicionales disponibles en [crear un panel de control](#), [panel de control de uso](#) y [descripción general de las tablas del sistema](#).

Conclusión

Migrar a Databricks requiere una planificación cuidadosa, ejecución precisa y optimización continua. Al seguir un enfoque estructurado, evaluar las cargas de trabajo, optimizar el código y aprovechar las potentes funcionalidades de Databricks, puede garantizar una migración fluida que mejore el rendimiento, la escalabilidad y la eficiencia de costos sin interrumpir las operaciones del negocio. Con Databricks, su organización puede escalar los pipelines de procesamiento de datos, a la vez que reduce los costos operativos y se prepara tanto para el éxito a corto plazo como para el crecimiento sostenible a largo plazo.

Sumérjase en más prácticas esenciales de ingeniería de datos e historias de clientes en el libro electrónico **Big Book of Data Engineering** (solo en inglés).

03

Estudios de casos



HISTORIA DEL CLIENTE

NFCU: Usar datos en tiempo real para abrir camino a la personalización de la experiencia de los miembros

INDUSTRIA Servicios financieros
NUBE Azure

Miles de millones

de eventos de aplicación por mes procesados por Spark Declarative Pipelines

9 mil millones

de eventos transmitidos de forma continua durante 9 meses, 24/7, sin mantenimiento

6 semanas

de tiempo de lanzamiento al mercado para una nueva aplicación omnicanal en tiempo real

La simplicidad del modelo de programación de Spark Declarative Pipelines, junto con sus capacidades de servicio, dio como resultado un tiempo de respuesta increíblemente rápido. Nos permitió llevar un tipo completamente nuevo de carga de trabajo a producción en tiempo récord y con buena calidad.

— Jian (Miracle) Zhou, gerente sénior de ingeniería, Navy Federal Credit Union

Siete empleados de la Marina de EE. UU. fundaron Navy Federal Credit Union durante la Gran Depresión, con el objetivo de ayudarse a sí mismos y a sus compañeros a alcanzar sus metas financieras. Hoy, Navy Federal Credit Union es la cooperativa de crédito más grande del mundo, con 13 millones de socios miembros. La prioridad de Navy Federal es proporcionar una experiencia personalizada y omnicanal a sus miembros. Pero para comprender mejor a sus miembros, necesitaba ingestar y analizar datos de telemetría en línea en tiempo real. Para lograr eso, Navy Federal recurrió a Spark Declarative Pipelines, Databricks SQL y Microsoft Power BI.

Los datos en tiempo casi real aportan nuevos insights

En junio de 2023, Navy Federal estaba a punto de comenzar el proceso de migrar a millones de usuarios a la versión más reciente de su plataforma de banca en línea. La empresa planeó completar esta migración de manera controlada con pequeños grupos de usuarios, expandiéndola gradualmente a todos sus miembros durante varios meses.

Para tomar decisiones informadas, Navy Federal necesitaba monitorear de cerca cómo los miembros interactuaban con su producto. Para lograr eso, los ingenieros de Navy Federal crearon pipelines de datos hacia su lago de datos, y los analistas de datos desarrollaron paneles de control e informes para visualizar los indicadores clave de rendimiento (KPI). Los procesos se realizaban a diario, por lo que la información del día anterior estaba disponible para los directivos al comienzo de cada nuevo día. “El pipeline funcionó a la perfección, pero en el mundo actual, 24 horas es un tiempo de respuesta largo”, dijo Jian (Miracle) Zhou, gerente sénior de ingeniería en Navy Federal Credit Union. “A medida que nos acercábamos a la primera fase de migración de usuarios, decidimos mejorar nuestra solución de datos para incorporar nueva información en tiempo casi real”.

Para lograrlo, la organización necesitaba crear un panel casi en tiempo real con dos indicadores clave: la cantidad de miembros únicos que lograron iniciar sesión en el nuevo canal y la cantidad de sesiones únicas que el canal atendió. Además, necesitaban filtrar los KPI tanto por tiempo como por atributo de miembro, que era el indicador de a qué fase de migración pertenecían. Se esperaba que el panel de control se actualizara continuamente durante todo el día con una latencia de no más de 10 minutos.

Zhou se enfrentó a dos desafíos principales: el tiempo y la escala. La organización solo tenía unas seis semanas para desarrollar una solución desde cero y llevarla a producción. “Esta fue realmente la primera vez que mi equipo intentó desarrollar una solución en tiempo real en Azure Cloud, y tuvimos que resolver todo en seis semanas”, dijo. “Y en términos de escala, estamos hablando de miles de millones de eventos de aplicaciones generados por millones de usuarios activos mensuales, por lo que la solución debía escalar a medida que avanzaba la migración”.

Databricks Spark Declarative Pipelines ayuda a crear pipelines de datos confiables y de alto rendimiento

Las soluciones de entrega de datos de Navy Federal siguen un camino sencillo y directo. Una parte es para ingenieros y se centra en la ingesta y curación de datos. Para cada fuente de datos, creaban una canalización de datos para incorporarlos a su lago de datos, transformarlos y prepararlos para que los clientes pudieran utilizarlos. Esta parte de la ecuación es muy dinámica debido a la diversidad de sus fuentes de datos. La otra parte está destinada a los analistas de datos y se centra en el servicio y la visualización de datos. Navy Federal usa Azure Data Lake Storage como su capa de almacenamiento, Databricks SQL como su motor de consulta analítica y Power BI para la visualización de datos. Juntos, forman una base simple, pero efectiva para el análisis de datos.

La fuente de los datos que Navy Federal necesitaba utilizar era la telemetría de eventos generada en su aplicación de banca en línea.

Navy Federal Credit Union enfrentó desafíos al usar Azure Application Insights para los paneles de control debido a la falta de acceso a los datos de atributos de los miembros. Para abordar esto, transmitieron la telemetría de Application Insights a su lago de datos con Azure Event Hubs, que admite el protocolo Kafka, y permite un consumo de datos de baja latencia y alta confiabilidad sin necesidad de codificación.

Para procesar los datos de transmisión, Navy Federal usó Databricks Spark Declarative Pipelines. Zhou y su equipo usaron Spark Declarative Pipelines para crear un pipeline de datos sencillo mediante la escritura de tres funciones de consulta y dos funciones de captura de cambios de datos. La primera función que escribieron se conecta a los centros de eventos, aplica algunas transformaciones y devuelve un marco de datos. La segunda función de consulta procesa documentos JSON complejos y los convierte en registros individuales de eventos de aplicación. Luego, utilizaron la función `APPLY CHANGES` de Spark Declarative Pipelines para eliminar los duplicados. En la tercera función de consulta, filtraron los datos para quedarse únicamente con los eventos de inicio de sesión y, luego, seleccionaron solo las columnas pertinentes al inicio de sesión.

Por último, volvieron a usar la función de aplicar los cambios para asegurarse de que no haya duplicados en la tabla de eventos de inicio de sesión. Por último, ayudaron a Spark Declarative Pipelines a comprender qué datos debían conservarse y cuáles podían permanecer en la memoria (pero sin ser accesibles al mundo exterior) cuando se ejecutaba una canalización. Luego, el equipo usó la característica "expectativas" para definir las expectativas de calidad de los datos y monitorear su integridad. "Eso es todo: tres funciones de consulta y dos llamadas CDC para completar los cuatro pasos. Así de simple", dijo Zhou. "Para mí, eso significa baja complejidad de código y un tiempo de desarrollo breve".

Es fundamental destacar que el canal creado por Zhou y su equipo se adapta de forma agresiva, lo cual era importante a medida que avanzaba la migración de usuarios omnicanal. "Comenzamos con una fase muy pequeña y continuamos aumentando el tamaño de la migración fase tras fase. Anticipábamos que esto incrementaría la demanda de recursos de cómputo, pero no teníamos certeza de cuánto sería necesario para cada fase. Así que, cuando desplegamos este pipeline de datos en producción, activamos una función llamada "Enhanced Autoscaling". El volumen de procesamiento aumentó con rapidez, y pasó de solo unos cientos de usuarios y unos pocos miles de sesiones diarias a millones de usuarios y miles de millones de eventos de aplicaciones al mes. Este flujo de trabajo escalaba de forma automática los recursos según el volumen de datos. Nuestros ingenieros de soporte de producción nunca tuvieron que intervenir. Prácticamente se olvidaron de ello". El pipeline también era confiable y tolerante a fallas. Funcionó en streaming continuo las 24 horas del día, los siete días de la semana, durante nueve meses y procesó con éxito unos 9000 millones de eventos de aplicaciones con un mantenimiento casi nulo. "Algunos días, hubo contratiempos que provocaron interrupciones temporales", dijo Zhou. "Esos contratiempos fueron una consecuencia natural de estar en el entorno de la nube. Lo mejor es que el pipeline mostró una gran resiliencia. Sin excepción, se recuperó automáticamente de esos errores transitorios".

El pipeline también fue eficiente. Incluso cuando el volumen de datos de eventos se disparó, el pipeline mantuvo el ritmo. "La velocidad de procesamiento de la transmisión y el tiempo de respuesta a las consultas fueron satisfactorios para nosotros. Parte de la razón fue que Spark Declarative Pipelines optimiza, compacta y realiza la limpieza automática de las tablas que gestiona", dijo Zhou. "Esto elimina o reduce de manera eficaz el problema de los archivos pequeños y elimina los archivos que ya no son necesarios de nuestra cuenta de almacenamiento, lo que da lugar a un mejor rendimiento de las consultas".

La última etapa del proyecto fue la entrega del panel de control. Databricks SQL les permitió organizar datos en Power BI con rapidez y a escala. "Nuestros analistas conectan Power BI a los datos de nuestro lago de datos a través del punto de conexión de Databricks SQL, construyen modelos semánticos en Power BI y generan información para las visualizaciones", explicó Zhou. "Nuestro panel de control consulta directamente a Databricks. Cuando se generan las visualizaciones, los usuarios reciben las actualizaciones más recientes en tiempo real".

Las canalizaciones declarativas de Spark llevan un nuevo tipo de carga de trabajo a producción en tiempo récord

Con Spark Declarative Pipelines, Navy Federal pudo completar una prueba de concepto en una semana; desarrollar, probar y definir un proceso CI/CD en tres semanas; desplegar el pipeline en producción justo antes de la fecha de inicio de la primera fase de migración y lanzar el panel de control solo unos días después.

"La simplicidad del modelo de programación de Spark Declarative Pipelines, junto con sus capacidades de servicio, dio como resultado un tiempo de respuesta increíblemente rápido", afirmó Zhou. "Nos permitió llevar un tipo completamente nuevo de carga de trabajo a producción en tiempo récord y con buena calidad".

El lanzamiento del panel de control de la actividad de los usuarios en tiempo real, combinado con las vistas históricas, reveló tendencias a largo plazo, lo que recibió una respuesta extremadamente positiva por parte de los principales directivos y las partes interesadas de Navy Federal.

“Spark Declarative Pipelines oculta la complejidad de la ingeniería de datos moderna bajo su modelo de programación declarativo, simple e intuitivo”, dijo Zhou. “Como gerente de ingeniería, me encanta el hecho de que mis ingenieros puedan concentrarse en lo que más importa para el negocio. Spark Declarative Pipelines puede encargarse de lo que ocurre detrás de escena y garantizar no solo que nuestro pipeline se construyó y desplegó a tiempo, sino que también se mantuvo de manera excelente a largo plazo”.

Tras el lanzamiento de la primera versión del nuevo pipeline a producción, Zhou y su equipo continuaron innovando y usaron Spark Declarative Pipelines para desarrollar y desplegar un marco propio basado en metadatos.

Zhou dijo que las tres cosas que más le gustan de Spark Declarative Pipelines son:

- El modelo de programación declarativa simple que aceleró el tiempo de llegada al mercado.
- La escalabilidad, optimización y fiabilidad integradas, que simplificaron las operaciones.
- La accesibilidad a través de la API, lo que permitió espacio para la creatividad en ingeniería y la escalabilidad.





HISTORIA DEL CLIENTE

Cincinnati Reds: Triunfar dentro y fuera del campo con analítica de béisbol de vanguardia

INDUSTRIA Medios de comunicación y entretenimiento
NUBE Azure

**3 a 5
veces**

mejor latencia con
Databricks Lakeflow
Jobs sin servidor

Miles

de horas de tiempo
de cómputo
ahorradas a diario

83 %

Disminución
del tiempo de
ejecución del
pipeline

Con Databricks Lakeflow Jobs sin servidor, hemos logrado mejorar la latencia entre 3 y 5 veces más. Lo que solía tardar 10 minutos ahora solo tarda entre 2 y 3 minutos, lo que reduce de manera significativa los tiempos de procesamiento. Esto nos ha permitido ofrecer bucles de retroalimentación más rápidos para los jugadores y los entrenadores, lo que garantiza que obtengan la información que necesitan casi en tiempo real para tomar decisiones prácticas.

— Bryce Dugar, gerente de Ingeniería de Datos, Cincinnati Reds

En el exigente mundo de las grandes ligas de béisbol, cada decisión y acción puede marcar la diferencia entre ganar y perder. Los Cincinnati Reds, conscientes de cómo los datos en tiempo real pueden ofrecer una ventaja competitiva, buscaron modernizar su infraestructura heredada, que era compleja de mantener a escala. Para acelerar sus cargas de trabajo y lograr una mayor eficiencia operativa, priorizaron las capacidades sin servidor como parte de su estrategia de transformación. Al adoptar la Databricks Data Intelligence Platform, han transformado por completo la forma en que gestionan y analizan grandes conjuntos de datos. Con Databricks Lakeflow Jobs, los procesos se automatizan y los pipelines de datos ofrecen información en tiempo real que impulsan decisiones más inteligentes y rápidas, que les proporcionan a los jugadores y entrenadores las herramientas necesarias para ganar al más alto nivel.

Los sistemas heredados fallan en ofrecer insights oportunos

Los Cincinnati Reds, una de las franquicias más antiguas de las Grandes Ligas de Béisbol, enfrentaban desafíos relacionados con infraestructura heredada y manejo de datos que limitaban su capacidad para tomar decisiones más inteligentes y rápidas en los ciclos de retroalimentación del béisbol, con el objetivo de ganar más partidos. En la última década, el volumen y la complejidad de los flujos de datos crecieron hasta 100 veces, impulsados por el auge de dispositivos y sensores de la Internet de las cosas (IoT) que registran el desempeño de los jugadores, la actividad en el estadio y la participación de los aficionados. Este crecimiento generó desafíos significativos para manejar y procesar datos en sus sistemas locales. El procesamiento de miles de millones de filas y consultas solía llevar horas o incluso días, lo que hacía que las aplicaciones en tiempo real resultaran poco prácticas. La escalabilidad era limitada, lo que obligaba a realizar soluciones manuales que consumían tiempo valioso.

La latencia también se había convertido en un factor crítico, ya que los usuarios esperaban acceso inmediato a la información e informes, los que antes solo estaban disponibles tras largas demoras. Además, los datos debían ser accesibles y utilizables para distintos roles: Desde científicos de datos que procesan grandes volúmenes de información y entrenan modelos para ayudar al equipo a hacer predicciones, hasta usuarios con menos formación técnica dentro de la organización que solo necesitan fragmentos de información para apoyar la toma de decisiones estratégicas. Además, los desarrolladores de aplicaciones requieren acceso programático a los almacenes de datos.

“Muchas de las tareas que realizábamos antes consistían simplemente en resolver problemas como filas faltantes o datos no procesados. Pasábamos horas solucionando esos problemas en lugar de dedicarnos a obtener información o mejorar el rendimiento. Nuestro equipo no podía seguir el ritmo del volumen y la variedad de datos creciente, y este enfoque manual nos dejó en desventaja, en especial, con la demanda de información en tiempo real en un deporte que se mueve tan rápido como el béisbol”, explicó Bryce Dugar, gerente de ingeniería de datos de los Cincinnati Reds.

Los Cincinnati Reds se dieron cuenta de que necesitaban una solución más escalable y eficiente, ya que sus necesidades de datos crecían con rapidez. Al reconocer las limitaciones de sus sistemas tradicionales, los Reds adoptaron la plataforma de inteligencia de datos de Databricks para automatizar los flujos de trabajo y permitir el acceso a los datos en tiempo real. En especial, con Databricks Lakeflow Jobs, la herramienta unificada de orquestación para datos, analítica e IA, buscaron definir, gestionar y supervisar más fácilmente los trabajos con múltiples tareas para ETL, reducir la intervención manual y proporcionar información más oportuna para mejorar la toma de decisiones.

Unificación de la orquestación de datos con Databricks Lakeflow Jobs

Con la plataforma Databricks como elemento central de su infraestructura de datos, Databricks Lakeflow Jobs se convirtió en un elemento clave para resolver los desafíos de los Reds, ya que adaptó la orquestación a sus necesidades específicas y se integró sin problemas a través de las API. Esto permitió activar tareas con parámetros, lo que permite un mayor control del flujo de trabajo. Los analistas obtuvieron independencia para desarrollar y ejecutar documentos interactivos con mejor trazabilidad y capacidades de procesamiento iterativo.

El equipo también adoptó una arquitectura sin servidores, lo que redujo significativamente la latencia. Anteriormente, el uso del cómputo en las tareas, incluso con grupos de recursos, a menudo provocaba demoras mientras se esperaba a que las tareas se iniciaran.

“Con Databricks Lakeflow Jobs sin servidor, hemos logrado una mejora de 3 a 5 veces en la latencia. Lo que solía tardar 10 minutos ahora solo tarda entre 2 y 3 minutos, lo que reduce de manera significativa los tiempos de procesamiento. Esto nos permitió ofrecer ciclos de retroalimentación más rápidos para jugadores y entrenadores, lo que garantizó que reciban los insights que necesitan casi en tiempo real para tomar decisiones accionables”, dijo Bryce.

Además de ahorrar tiempo, el equipo observó una reducción del 65 al 80 % en los costos de las máquinas virtuales al pasarse a Databricks Lakeflow Jobs sin servidor, lo que hizo que la solución no solo fuera más rápida, sino también mucho más rentable. Dado que los Reds ejecutaban entre 15 000 y 20 000 pasos de flujo de trabajo al día, esta eficiencia ahorró cientos de miles de minutos de cómputo diariamente, lo que permitió manejar nuevas cargas de trabajo y acelerar la entrega de informes.

El equipo hizo la transición de Azure Data Factory a Databricks. “Con Databricks, transformamos por completo la forma en que manejamos los datos. Pasar a una arquitectura sin servidor y aprovechar Databricks Lakeflow Jobs sin servidor no solo optimizó nuestros pipelines, sino que también redujo radicalmente la latencia hasta en un 83 %”, afirmó Bryce. “Lo que solía tomar una hora ahora se puede realizar en 10 minutos, lo que nos permite ejecutar más procesos, entregar informes más rápido y proporcionar retroalimentación casi al instante para el entrenamiento y desarrollo de los jugadores. Ha sido un cambio radical en la forma en que tomamos decisiones en tiempo real en un deporte tan dinámico como el béisbol”.

El entorno sin servidor de la plataforma eliminó las restricciones relacionadas con la memoria y los núcleos de procesamiento. Esto permitió al equipo gestionar consultas de datos grandes y complejas de manera más eficiente, lo que facilitó obtener información más rápida y precisa para tomar decisiones durante los días de partido. La trazabilidad de los flujos de trabajo (desde la ingesta de datos hasta el resultado final) también mejoró la rendición de cuentas, lo que facilitó al equipo la supervisión, resolución de problemas y optimización de sus pipelines de datos. Los científicos de datos e ingenieros ya no se enfrentan a inestabilidad del sistema, cierres inesperados de sesiones ni a largos tiempos de procesamiento, lo que facilita flujos de trabajo más fluidos y aumenta la satisfacción laboral. Además, la naturaleza modular y automatizada de Databricks Lakeflow Jobs redujo significativamente la carga para los desarrolladores, lo que les permitió concentrarse en trabajo de alto valor.

Los datos más rápidos se traducen en decisiones que ganan partidos

La transición a la computación sin servidor redujo significativamente la latencia de los trabajos y disminuyó los pasos del proceso de 10 a 15 minutos a tan solo 2 o 3 minutos. Con la racionalización de procesos de Databricks Lakeflow Jobs, las tareas de ETL y los flujos de trabajo de ciencia de datos ahora operan con mayor velocidad y agilidad.

Esta eficiencia garantiza una disponibilidad de datos pospartido sumamente rápida, lo que brinda a los entrenadores información prácticamente en tiempo real para hacer ajustes fundamentales y proporcionar retroalimentación inmediata a los jugadores.

Bryce concluyó: “Gracias a Databricks, el ahorro de tiempo que hemos logrado es casi incalculable, lo que nos permite hacer cosas que antes ni siquiera podíamos considerar. Este cambio ha modificado fundamentalmente nuestra forma de operar y la velocidad con la que podemos enviar información a los entrenadores, jugadores y analistas”. Este cambio transformador ha consolidado a Databricks Lakeflow Jobs como un facilitador clave en la estrategia basada en datos de los Reds, lo que empodera al equipo para tomar decisiones más inteligentes y rápidas en el mundo de alta presión del béisbol profesional.

Sumérjase en más prácticas esenciales de ingeniería de datos e historias de clientes en el libro electrónico **Big Book of Data Engineering** (solo en inglés).

Ingerir, transformar y orquestar con una solución unificada de ingeniería de datos

Databricks Lakeflow se diseñó para abordar los desafíos principales que enfrentan hoy los equipos de ingeniería de datos. Como una solución de ingeniería de datos integral que incorpora inteligencia de datos, Lakeflow unifica y simplifica la ingesta, la transformación y la orquestación de datos al ofrecer un enfoque singular para la creación de pipelines de datos.

[Más información](#)[Vea una demostración](#)[Pruebe Databricks gratis](#)

Acerca de Databricks

Databricks es una empresa de datos e IA. Más de 15 000 organizaciones en todo el mundo, lo que incluye Block, Comcast, Condé Nast, Rivian, Shell y más del 60 % de las empresas Fortune 500, confían en la plataforma de inteligencia de datos de Databricks para tomar el control de sus datos y aprovecharlos con IA. Databricks tiene su sede en San Francisco, con oficinas en todo el mundo, y fue fundada por los creadores originales de Lakehouse, Apache Spark™, Delta Lake, MLflow y Unity Catalog. Para más información, siga a Databricks en [LinkedIn](#), [X](#) y [Facebook](#).

